

Distribution de Dirichlet

La distribution de Dirichlet est une distribution de probabilité continue multivariée utilisée pour modéliser des variables aléatoires $\boldsymbol{\theta} = (\theta_1, \dots, \theta_K)$ tels que $\sum_{i=1}^K \theta_i = 1$ et $\theta_i \in [0, 1], \forall i$. La distribution de Dirichlet est caractérisée par le vecteur de paramètres $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_K)$, avec $\alpha_i > 0, \forall i$. La fonction de densité de probabilité est donnée par :

$$p(\theta_1, \dots, \theta_K; \alpha_1, \dots, \alpha_K) = \frac{1}{B(\boldsymbol{\alpha})} \prod_{i=1}^K \theta_i^{\alpha_i-1}, \quad (1)$$

où la constante de normalization est la fonction beta :

$$B(\boldsymbol{\alpha}) = \frac{\prod_{i=1}^K \Gamma(\alpha_i)}{\Gamma\left(\sum_{i=1}^K \alpha_i\right)},$$

avec $\Gamma(\cdot)$ denotant la fonction gamma :

$$\Gamma(z) = \int_0^{+\infty} t^{z-1} e^{-t} dt.$$

Si n est un nombre entier, alors la fonction gamma est donnée par :

$$\Gamma(n) = (n-1)!$$

Notons les propriétés suivantes :

— Etant donné $\int_{\boldsymbol{\theta}} p(\boldsymbol{\theta}, \boldsymbol{\alpha}) d\boldsymbol{\theta} = 1$, nous avons l'égalité suivante :

$$\int_{\boldsymbol{\theta}} \prod_{i=1}^K \theta_i^{\alpha_i-1} d\boldsymbol{\theta} = B(\boldsymbol{\alpha}) = \frac{\prod_{i=1}^K \Gamma(\alpha_i)}{\Gamma\left(\sum_{i=1}^K \alpha_i\right)}. \quad (2)$$

— L'espérance de chaque variable aléatoire θ_i est proportionnelle à α_i :

$$\mathbb{E}[\theta_i] \propto \alpha_i. \quad (3)$$

— La distribution de Dirichlet est souvent utilisée comme distribution *a priori* pour les paramètres d'une distribution multinomiale car la distribution de Dirichlet est un *conjugate prior* pour la distribution multinomiale. Soient $\theta_1, \dots, \theta_K$ les paramètres de la distribution multinomiale. Si la distribution *a priori* est une distribution de Dirichlet :

$$(\theta_1, \dots, \theta_K) \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K),$$

alors la distribution *a posteriori* est également une distribution de Dirichlet :

$$(\theta_1, \dots, \theta_K | n_1, \dots, n_K) \sim \text{Dirichlet}(\alpha_1 + n_1, \dots, \alpha_K + n_K),$$

où n_i est le nombre observé d'occurrences de la catégorie i dans les données. Etant donné (3), l'espérance *a posteriori* de θ_i est donnée par :

$$\mathbb{E}[\theta_i | n_i] \propto \alpha_i + n_i. \quad (4)$$

— Si $x_1 \rightarrow +\infty$, alors nous avons l'approximation suivante :

$$\frac{\Gamma(x_1 + x_2)}{\Gamma(x_1)} \simeq x_1^{x_2}. \quad (5)$$