

Projet de Processus Stochastiques

Détection de motifs par méthodes MCMC

Franck Duval HEUBA - S227629

Année Académique 2025-2026

Table des matières

1	Chaînes de Markov et échantillonnage de Gibbs	2
1.1	Chaînes de Markov	2
1.1.1	Estimation de la matrice P	2
1.1.2	Évolution temporelle	3
1.1.3	Distribution stationnaire	4
1.1.4	Ergodicité	4
1.1.5	Évaluation de séquences	5
1.2	Échantillonnage de Gibbs	7
1.2.1	Preuve de la stationnarité de l'échantillonneur de Gibbs	7
1.2.2	Implémentation et comparaison des stratégies de balayage	8
2	Détection de motifs	9
2.1	Dérivations mathématiques	9
2.2	Implémentation et gestion des décalages	10
2.3	Expérimentations et évaluation (Question 2.2.3)	11
3	Conclusion	13

1 Chaînes de Markov et échantillonnage de Gibbs

1.1 Chaînes de Markov

1.1.1 Estimation de la matrice P

Pour modéliser la séquence d'ADN fournie (**seq1**) sous forme de chaîne de Markov, nous devons estimer sa matrice de transition P . Les états de la chaîne correspondent aux quatre nucléotides, numérotés de 1 à 4 : A (1), C (2), G (3), et T (4).

La probabilité de transition de l'état i vers l'état j , notée $P_{i,j}$, s'estime par la méthode du maximum de vraisemblance (MLE). Cet estimateur correspond à la fréquence empirique des transitions observées dans la séquence :

$$\hat{P}_{i,j} = \frac{N_{i,j}}{\sum_{k=1}^4 N_{i,k}} \quad (1)$$

où $N_{i,j}$ représente le nombre de fois où le nucléotide i est immédiatement suivi du nucléotide j dans **seq1**.

En appliquant cette formule sur notre séquence, nous obtenons la matrice de transition empirique suivante (arrondie à 3 décimales) :

$$P = \begin{pmatrix} P_{AA} & P_{AC} & P_{AG} & P_{AT} \\ P_{CA} & P_{CC} & P_{CG} & P_{CT} \\ P_{GA} & P_{GC} & P_{GG} & P_{GT} \\ P_{TA} & P_{TC} & P_{TG} & P_{TT} \end{pmatrix} = \begin{pmatrix} 0.097 & 0.505 & 0.278 & 0.120 \\ 0.253 & 0.246 & 0.262 & 0.239 \\ 0.311 & 0.493 & 0.108 & 0.089 \\ 0.696 & 0.098 & 0.098 & 0.108 \end{pmatrix} \quad (2)$$

Diagramme d'états Le graphe orienté ci-dessous illustre la dynamique de cette chaîne de Markov. Les nœuds représentent les états (A, C, G, T) et les arêtes indiquent les probabilités de transition $\hat{P}_{i,j}$.




FIGURE 1 – Diagramme d'états de la chaîne de Markov modélisant **seq1**.

1.1.2 Évolution temporelle

Pour étudier la dynamique temporelle de notre chaîne de Markov, nous calculons la distribution de probabilité des états au temps t , notée u_t . Si la chaîne possède un vecteur de probabilité initial u_0 , la distribution au temps t est donnée par l'équation :

$$u_t = u_0 P^t \quad (3)$$

Nous avons simulé cette évolution sur 20 étapes temporelles pour deux conditions initiales distinctes :

1. Une distribution initiale uniforme : $u_0 = (0.25, 0.25, 0.25, 0.25)$.
2. Un départ certain depuis le nucléotide 'C' : $u_0 = (0, 1, 0, 0)$.

La Figure 2 illustre les résultats obtenus.




FIGURE 2 – Évolution de la probabilité de se trouver dans chaque état (A, C, G, T) au cours du temps, pour deux conditions initiales différentes.

Analyse des observations Nous remarquons que, bien que les trajectoires des premières étapes soient très différentes selon la condition initiale, les probabilités finissent par se stabiliser et converger vers des valeurs constantes après environ $t = 3$ itérations.

On remarque que peu importe la condition initiale, les probabilités convergent vers le même ordre $P(C) > P(A) > P(G) > P(T)$. Cependant quand la distribution initiale est uniforme on a plus d'écart de chance à long terme que lorsqu'au départ on a un C.

En calculant la matrice P^t pour une valeur de t suffisamment grande (par exemple $t = 50$), nous observons le résultat suivant :

$$P^{50} \approx \begin{pmatrix} 0.2881 & 0.3497 & 0.2091 & 0.1531 \\ 0.2881 & 0.3497 & 0.2091 & 0.1531 \\ 0.2881 & 0.3497 & 0.2091 & 0.1531 \\ 0.2881 & 0.3497 & 0.2091 & 0.1531 \end{pmatrix} \quad (4)$$

Les lignes de la matrice P^t deviennent toutes identiques. Cela s'explique mathématiquement : l'élément (i, j) de P^t représente la probabilité de se trouver dans l'état j après t étapes en partant de l'état i . Le fait que toutes les lignes soient égales signifie que pour

un temps t suffisamment long, la probabilité d'être dans un état donné ne dépend plus du tout de l'état de départ. La chaîne a "oublié" sa condition initiale lors qu'elle converge vers la distribution stationnaire.

1.1.3 Distribution stationnaire

La distribution stationnaire d'une chaîne de Markov, notée π_∞ , est une distribution de probabilité qui reste invariante lors de l'application de la matrice de transition P . Mathématiquement, elle satisfait le système d'équations suivant :

$$\pi_\infty P = \pi_\infty \quad \text{soumis à la contrainte} \quad \sum_{i \in \mathcal{S}} (\pi_\infty)_i = 1 \quad (5)$$

D'un point de vue algébrique, cela signifie que π_∞ est le vecteur propre à gauche de la matrice P associé à la valeur propre $\lambda = 1$.

Plutôt que d'estimer cette distribution en élevant P à une grande puissance (comme fait précédemment), nous l'avons calculée analytiquement en procédant à la décomposition spectrale de la transposée de la matrice P (P^T).

Après extraction du vecteur propre correspondant à la valeur propre $\lambda = 1$ et normalisation pour que la somme de ses éléments vaille 1, nous obtenons la distribution stationnaire suivante :

$$\pi_\infty = \begin{pmatrix} \pi_A \\ \pi_C \\ \pi_G \\ \pi_T \end{pmatrix}^T = \begin{pmatrix} 0.2881 \\ 0.3497 \\ 0.2091 \\ 0.1531 \end{pmatrix}^T \quad (6)$$

Conclusion sur la convergence Nous constatons que ce calcul analytique direct corrobore parfaitement l'observation empirique de la question précédente (1.1.2). Les valeurs de π_∞ correspondent exactement aux probabilités vers lesquelles les lignes de la matrice P^{50} avaient convergé. La chaîne de Markov modélisant notre séquence d'ADN possède donc bien une unique distribution stationnaire vers laquelle le système tend asymptotiquement, quelle que soit sa condition initiale.

1.1.4 Ergodicité

Une chaîne de Markov est dite ergodique si elle est irréductible (il est possible d'atteindre n'importe quel état depuis n'importe quel autre) et apériodique. Pour une telle chaîne, le théorème ergodique stipule que la proportion du temps passé dans un état i sur une trajectoire infiniment longue converge vers la probabilité stationnaire π_i de cet état :

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{t=1}^N \mathbf{1}_{\{X_t=i\}} = \pi_i \quad (7)$$

Pour vérifier expérimentalement cette propriété, nous avons simulé une trajectoire de la chaîne en générant une nouvelle séquence artificielle de $N = 50\,000$ nucléotides. À chaque étape, la transition vers le nucléotide suivant a été tirée aléatoirement en respectant strictement les probabilités de la matrice de transition P estimée à la Question 1.1.1.

Nous avons ensuite calculé les fréquences empiriques d'apparition de chaque nucléotide dans cette séquence générée.

Le tableau ci-dessous compare ces fréquences empiriques temporelles avec la distribution stationnaire π_∞ calculée analytiquement à la Question 1.1.3 :

Nucléotide	Fréquence empirique (N=50 000)	Distribution stationnaire (π_∞)
A	0.2879	0.2881
C	0.3483	0.3497
G	0.2117	0.2091
T	0.1521	0.1531

Conclusion Nous constatons que les fréquences empiriques observées sur une longue réalisation de la chaîne sont extrêmement proches des probabilités de la distribution stationnaire π_∞ (aux fluctuations statistiques d'échantillonnage près). Cela confirme numériquement que notre modèle de séquence d'ADN forme bien une chaîne de Markov ergodique : l'exploration temporelle du système (simulée sur 50 000 étapes) reflète fidèlement son équilibre spatial théorique.

1.1.5 Évaluation de séquences

Comparaison des fréquences empiriques Avant d'évaluer les séquences avec notre modèle de Markov, nous avons calculé la fréquence d'apparition simple (modèle d'ordre 0) de chaque nucléotide pour les trois séquences fournies :

Séquence	Fréq. A	Fréq. C	Fréq. G	Fréq. T
Séquence 1	0.2885	0.3495	0.2090	0.1530
Séquence 2	0.3060	0.3415	0.1970	0.1555
Séquence 3	0.2845	0.3605	0.1985	0.1565

L'analyse de ce tableau révèle que : *Seq1, Seq2 et Seq3 ont des distributions très similaires.*

Évaluation par le modèle de Markov Afin d'évaluer plus finement dans quelle mesure ces séquences sont compatibles avec la dynamique de **seq1**, nous calculons la probabilité d'observer chacune d'entre elles sous l'hypothèse qu'elles ont été générées par notre chaîne de Markov.

La vraisemblance d'une séquence $S = (x_1, x_2, \dots, x_L)$ s'écrit :

$$\mathbb{P}(S \mid P) = \pi_\infty(x_1) \prod_{t=1}^{L-1} P_{x_t, x_{t+1}} \quad (8)$$

Pour éviter l'underflow numérique dû au produit de milliers de probabilités, nous utilisons la log-vraisemblance moyenne par nucléotide :

$$\frac{1}{L} \log \mathbb{P}(S | P) = \frac{1}{L} \left(\log(\pi_{\infty}(x_1)) + \sum_{t=1}^{L-1} \log(P_{x_t, x_{t+1}}) \right) \quad (9)$$

Les résultats obtenus pour les trois séquences sont les suivants :

- **Séquence 1** : Log-vraisemblance moyenne = -1.2140
- **Séquence 2** : Log-vraisemblance moyenne = -1.4864
- **Séquence 3** : Log-vraisemblance moyenne = -1.2005

Conclusion : Comparaison et puissance du modèle de Markov L'analyse conjointe des fréquences empiriques et des log-vraisemblances révèle l'intérêt fondamental de la modélisation par chaînes de Markov.

Dans un premier temps, l'observation des fréquences d'apparition simples montre que les trois séquences possèdent une composition globale quasi-identique (environ 29% de A, 35% de C, 20% de G et 16% de T). Sur la seule base de ces comptages, on pourrait conclure que ces trois séquences proviennent du même processus stochastique.

Cependant, l'évaluation par la log-vraisemblance met en lumière une réalité différente, car elle prend en compte la dynamique temporelle (les probabilités de transition entre nucléotides adjacents) :

- **La Séquence 3** obtient une log-vraisemblance moyenne (-1.2005) extrêmement proche de celle de la Séquence 1 (-1.2140), sur laquelle le modèle a été entraîné. Cela prouve que la Séquence 3 partage la même "signature" de transitions stochastiques que la Séquence 1. Elles ont très certainement été générées par le même processus.
- **La Séquence 2**, en revanche, obtient une log-vraisemblance nettement inférieure (-1.4864). L'échelle étant logarithmique sur 2000 caractères, cette différence indique que la probabilité que la Séquence 2 ait été générée par notre matrice P est infime.

Nous pouvons donc conclure que bien que la Séquence 2 utilise les mêmes proportions de nucléotides que la Séquence 1, leur ordonnancement est fondamentalement différent. Le modèle de Markov réussit là où le simple comptage échoue : il détecte que la Séquence 2 est une anomalie générée par un processus (ou un modèle de fond biologique) distinct.

1.2 Échantillonnage de Gibbs

1.2.1 Preuve de la stationnarité de l'échantillonneur de Gibbs

L'objectif est de démontrer que la distribution jointe $p(Y)$ est la distribution stationnaire de la chaîne de Markov construite par l'algorithme de Gibbs. Pour ce faire, nous allons prouver que cette chaîne satisfait la **condition de balance détaillée**.

Définition du noyau de transition Soit $y = (y_1, \dots, y_n)$ l'état actuel de la chaîne. Dans l'échantillonneur de Gibbs à balayage aléatoire, une transition vers un état y' se déroule comme suit :

1. On choisit un indice $j \in \{1, \dots, n\}$ avec une probabilité uniforme $1/n$.
2. On met à jour la j -ème composante en tirant $y'_j \sim p(Y_j \mid Y_{-j} = y_{-j})$.

L'état d'arrivée est donc $y' = (y'_j, y_{-j})$. Si y et y' diffèrent par plus d'une composante, la probabilité de transition $P(y \rightarrow y')$ est nulle.

Démonstration par la balance détaillée Considérons deux états y et y' ne différant que par la composante j . La probabilité de transition est :

$$P(y \rightarrow y') = \frac{1}{n} p(y'_j \mid y_{-j}) \quad (10)$$

Vérifions si le flux de probabilité entre y et y' est équilibré, c'est-à-dire si $p(y)P(y \rightarrow y') = p(y')P(y' \rightarrow y)$.

En utilisant la définition de la probabilité conditionnelle $p(y) = p(y_j \mid y_{-j})p(y_{-j})$, le membre de gauche devient :

$$\begin{aligned} p(y)P(y \rightarrow y') &= [p(y_j \mid y_{-j})p(y_{-j})] \times \left[\frac{1}{n} p(y'_j \mid y_{-j}) \right] \\ &= \frac{1}{n} p(y_j \mid y_{-j}) p(y'_j \mid y_{-j}) p(y_{-j}) \end{aligned} \quad (11)$$

De la même manière, pour le flux inverse partant de $y' = (y'_j, y_{-j})$ vers $y = (y_j, y_{-j})$:

$$\begin{aligned} p(y')P(y' \rightarrow y) &= [p(y'_j \mid y_{-j})p(y_{-j})] \times \left[\frac{1}{n} p(y_j \mid y_{-j}) \right] \\ &= \frac{1}{n} p(y'_j \mid y_{-j}) p(y_j \mid y_{-j}) p(y_{-j}) \end{aligned} \quad (12)$$

Nous observons que les deux expressions sont identiques. La condition de balance détaillée est respectée :

$$p(y)P(y \rightarrow y') = p(y')P(y' \rightarrow y) \quad (13)$$

Conclusion La balance détaillée implique que la distribution $p(Y)$ est invariante par le noyau de transition de Gibbs. Puisque $p(Y)$ est stationnaire et que la chaîne est (sous réserve de positivité de la densité) irréductible et apériodique, la chaîne de Markov convergera vers $p(Y)$ indépendamment de l'état initial $y^{(0)}$.

Note sur l'implémentation : Lors de la mise en œuvre pratique (Question 1.2.2), le tirage selon la loi conditionnelle $p(Y_j \mid Y_{-j})$ sera effectué en appliquant la **Proposition 3.6.3** via la méthode de la transformée inverse.

1.2.2 Implémentation et comparaison des stratégies de balayage

(a) **Choix de la distribution jointe Q_Y** Nous définissons une distribution jointe sur deux variables $Y_1, Y_2 \in \{1, 2, 3, 4\}$ par la matrice $Q_Y \in \mathbb{R}^{4 \times 4}$ suivante :

$$[Q_Y]_{i,j} = \frac{i+j}{80}, \quad \forall i, j \in \{1, \dots, 4\} \quad (14)$$

Cette distribution respecte la condition de positivité ($Q_Y > 0$), ce qui garantit que la chaîne de Markov est **irréductible** et **apériodique**. Ces deux conditions assurent, selon la théorie du point 1, que l'algorithme de Gibbs convergera vers l'unique distribution stationnaire Q_Y .

(b) **Réalisation par balayage aléatoire (Algorithme 1)** Nous avons généré une chaîne de 50 000 itérations en choisissant à chaque étape l'indice de la variable à mettre à jour uniformément dans $\{1, 2\}$. Les tirages selon les lois conditionnelles $P(Y_1 | Y_2)$ et $P(Y_2 | Y_1)$ ont été effectués via la méthode de la transformée inverse. La Figure 3 montre que les fréquences empiriques épousent parfaitement les valeurs théoriques de Q_Y .

(c) **Balayage systématique et conclusion** L'expérience a été répétée en utilisant un balayage systématique (mise à jour de Y_1 puis de Y_2 à chaque itération). Les résultats obtenus sont statistiquement identiques à ceux du balayage aléatoire.




FIGURE 3 – Comparaison des fréquences d'états pour les deux stratégies de balayage de Gibbs par rapport à la distribution cible.

En conclusion, les deux méthodes de balayage (aléatoire et systématique) conduisent à des résultats similaires en termes de convergence vers la distribution cible Q_Y .

2 Détection de motifs

2.1 Dérivations mathématiques

Question 2.2.1 : Lois conditionnelles de l'échantillonneur de Gibbs Dans le cadre de la découverte de motifs *de novo*, l'échantillonneur de Gibbs alterne entre l'échantillonnage des paramètres du motif Θ et l'échantillonnage des positions de départ $\mathcal{A} = \{A_1, \dots, A_N\}$. Nous dérivons ci-dessous les deux distributions conditionnelles nécessaires à cet algorithme.

1. Distribution du profil de motif sachant les positions : $p(\Theta \mid \mathcal{A}, \mathcal{S}, \Phi)$ Par l'application du théorème de Bayes, la distribution a posteriori des paramètres du motif est proportionnelle au produit de la vraisemblance des données et de la distribution a priori :

$$p(\Theta \mid \mathcal{A}, \mathcal{S}, \Phi) \propto p(\mathcal{S} \mid \mathcal{A}, \Theta, \Phi) \cdot p(\Theta) \quad (15)$$

Pour chaque colonne $j \in \{1, \dots, W\}$ du motif, nous modélisons la distribution a priori $p(\Theta_j)$ par une loi de Dirichlet de paramètres $\alpha = (\alpha_A, \alpha_C, \alpha_G, \alpha_T)$:

$$p(\Theta_j) \sim \text{Dirichlet}(\alpha) \propto \prod_{i \in \{A, C, G, T\}} \Theta_{i,j}^{\alpha_i - 1} \quad (16)$$

Étant donné les positions $\mathcal{A}$, les sous-séquences correspondant aux motifs sont parfaitement identifiées. Soit $n_{i,j}$ le nombre d'occurrences du nucléotide i à la position j du motif à travers toutes les séquences de $\mathcal{S}$. La vraisemblance de ces observations suit une loi multinomiale :

$$p(\text{motifs} \mid \Theta) \propto \prod_{i \in \{A, C, G, T\}} \Theta_{i,j}^{n_{i,j}} \quad (17)$$

Puisque la loi de Dirichlet est l'a priori conjugué de la loi multinomiale, le produit des deux équations précédentes montre que la distribution a posteriori pour chaque colonne j reste une loi de Dirichlet, dont les paramètres sont mis à jour en ajoutant les comptages observés $n_{i,j}$ aux pseudo-comptes α_i :

$$\Theta_j \mid \mathcal{A}, \mathcal{S} \sim \text{Dirichlet}(\alpha_A + n_{A,j}, \alpha_C + n_{C,j}, \alpha_G + n_{G,j}, \alpha_T + n_{T,j}) \quad (18)$$

2. Distribution de la position sachant le motif : $p(A_k = a \mid \mathcal{A}_{-k}, \Theta, \mathcal{S}, \Phi)$ Nous cherchons la probabilité que le motif commence à la position a dans la séquence S_k , sachant le profil Θ . La position A_k est conditionnellement indépendante des autres positions $\mathcal{A}_{-k}$ étant donné Θ .

Par le théorème de Bayes, cette probabilité est proportionnelle à la probabilité de générer la séquence S_k avec un motif commençant en a :

$$P(A_k = a \mid \Theta, S_k, \Phi) = \frac{P(S_k \mid A_k = a, \Theta, \Phi) P(A_k = a)}{\sum_{a'} P(S_k \mid A_k = a', \Theta, \Phi) P(A_k = a')} \quad (19)$$

En supposant un a priori uniforme sur les positions possibles ($P(A_k = a)$ constant), nous pouvons évaluer la vraisemblance de la séquence. La séquence est composée de la

région du motif (générée par Θ) et du reste de la séquence (généré par le modèle de fond Φ).

Pour simplifier les calculs, nous divisons cette vraisemblance par la probabilité constante $P(S_k | \Phi)$ (probabilité que toute la séquence soit du bruit de fond). Les termes du bruit de fond s'annulent partout, sauf sur la fenêtre du motif, ce qui nous donne le poids w_a :

$$w_a = \prod_{j=0}^{W-1} \frac{\Theta_{S_k, a+j, j}}{\Phi_{S_k, a+j}} \quad (20)$$

où $S_{k, a+j}$ est le nucléotide présent à la position $a + j$ dans la séquence S_k .

La probabilité conditionnelle est finalement obtenue en normalisant ces poids sur toutes les positions de départ valides (de 1 à $L - W + 1$, où L est la longueur de la séquence) :

$$P(A_k = a | \Theta, S_k, \Phi) = \frac{w_a}{\sum_{a'=1}^{L-W+1} w_{a'}} \quad (21)$$

C'est dans cette distribution discrète que la nouvelle position A_k sera échantillonnée (par la méthode de la transformée inverse vue à la Partie 1).

2.2 Implémentation et gestion des décalages

Question 2.2.2 : Architecture de l'algorithme de Gibbs L'algorithme a été implémenté en Python en suivant scrupuleusement les dérivations de la question 2.2.1. Les points clés de notre implémentation sont les suivants :

1. **Stabilité numérique** : Le calcul des poids w_a pour les positions utilise le ratio entre la probabilité sous le modèle du motif Θ et le modèle de fond Φ . Cela permet de mettre en évidence le signal du motif par rapport au bruit.
2. **Tirage de Dirichlet** : Nous utilisons la fonction `numpy.random.dirichlet` pour échantillonner la matrice Θ . Les pseudo-comptes α sont fixés à 1 (prior de Laplace) pour assurer qu'aucun nucléotide n'ait une probabilité nulle, ce qui rendrait le calcul des ratios impossible.
3. **Gestion du Phase Shift** : Un problème classique de l'échantillonneur de Gibbs est sa tendance à converger vers un motif décalé de quelques bases (optimum local). Pour pallier cela, nous avons introduit un mouvement de décalage global (Phase Shift) toutes les 10 itérations. Ce mouvement propose de décaler l'ensemble des positions $\mathcal{A}$ d'une unité. Ce saut permet à l'algorithme de s'échapper d'un alignement imparfait.

Pseudo-code de la boucle principale

```

1 Initialiser A au hasard
2 Pour i de 1 a MaxIter:
3     1. Compter les nucleotides dans les fenetres definies par A
4     2. Tirer Theta ~ Dirichlet(alpha + counts)
5     3. Pour chaque sequence k:
6         Recalculer les poids w_a pour chaque position de depart
7         Tirer Ak ~ Multinomiale(Normaliser(w))
8     4. Si i % 10 == 0:
9         Tenter un Phase Shift (Metropolis-Hastings)
```

2.3 Expérimentations et évaluation (Question 2.2.3)

Afin d'évaluer quantitativement les performances de notre implémentation de l'échantillonneur de Gibbs, nous avons utilisé deux métriques standards en découverte de motifs :

- **Le Score de Consensus (Contenu en Information)** : Il mesure la conservation du motif trouvé en calculant l'entropie de Shannon sur la matrice Θ . Pour un motif de longueur W , le score maximal est de $2W$ bits.
- **L'Average Jaccard Index (AJI)** : Il mesure le taux de chevauchement moyen entre les positions prédites par notre algorithme et les positions réelles connues (fournies dans les fichiers de vérité terrain). Un score de 1.0 indique une prédiction parfaite sur toutes les séquences.

1. Validation sur le jeu de données artificielles Nous avons lancé l'algorithme sur le fichier `sequences_artif.txt` avec une largeur de motif $W = 10$ et le modèle de fond Φ fourni. Pour pallier les optima locaux, une approche par redémarrages multiples a été utilisée (10 chaînes indépendantes de 500 itérations).

Métrique	Résultat (Données Artificielles)
Score de Consensus	8.71 bits (Max théorique : 20 bits)
Average Jaccard Index (AJI)	0.8001

Analyse : Les résultats sur les données synthétiques valident notre implémentation. Un AJI de 0.80 démontre que l'échantillonneur, couplé à la stratégie de *Phase Shift* et de redémarrages multiples, évite avec succès les optima locaux décalés et converge vers les véritables coordonnées du motif. Le score de consensus de 8.71 bits, bien qu'inférieur au maximum théorique, reflète avec précision l'entropie inhérente à la matrice de probabilités génératrice (définie dans `artif_motif_parameters.txt`).

2. Application aux données biologiques réelles (PurR) L'algorithme a ensuite été confronté au problème biologique de l'identification des sites de fixation du répresseur PurR chez *E. coli* (`sequences-purrr.txt`). Le modèle de fond Φ a été estimé empiriquement (modèle de Markov d'ordre 0) et W a été fixé à 16.

Métrique	Résultat (Données PurR)
Score de Consensus	13.73 bits (Max théorique : 32 bits)
Average Jaccard Index (AJI)	0.4430

Analyse et conclusion : L'analyse de séquences biologiques *in vivo* révèle les limites d'un modèle stochastique simpliste. La baisse de l'AJI (0.4430, soit un chevauchement moyen d'environ la moitié du motif) et l'obtention d'un score de consensus modéré (13.73 bits) s'expliquent par deux facteurs majeurs :

1. **La dégénérescence biologique** : Les véritables sites de fixation de PurR sont soumis à une variabilité évolutive naturelle (mutations silencieuses, "wobble"), ce qui rend le motif intrinsèquement moins pur qu'un signal mathématique strict.

2. **Les limites du modèle de fond :** Le modèle Φ d'ordre 0 suppose que l'ADN hors-motif est généré de manière purement aléatoire et indépendante. En réalité, le génome de *E. coli* possède des structures complexes (biais GC, îlots CpG, régions codantes) qui créent de "faux signaux" locaux. Ces biais attirent l'échantillonneur vers des optima locaux biologiques (faux positifs).

Néanmoins, notre implémentation Bayésienne parvient à isoler un profil Θ cohérent.

3 Conclusion

Ce projet a permis d’explorer les fondements théoriques et les applications pratiques des processus stochastiques à travers le problème complexe de la détection de motifs ADN. Le passage d’une analyse statistique simple (comptage de fréquences) à une modélisation par chaînes de Markov de premier ordre a mis en évidence l’importance de la dynamique de transition pour caractériser la signature statistique d’une séquence.

Synthèse des résultats La première partie du travail a validé les propriétés fondamentales des chaînes de Markov : l’estimation par maximum de vraisemblance, la convergence vers une distribution stationnaire unique et l’ergodicité du système. L’implémentation de l’échantillonneur de Gibbs sur un modèle jouet a ensuite démontré la capacité de cet algorithme MCMC à converger vers une distribution jointe multidimensionnelle en utilisant uniquement des tirages conditionnels.

Dans la seconde partie, l’application de l’échantillonnage de Gibbs à la bioinformatique a révélé la puissance de l’inférence Bayésienne. L’utilisation d’un *prior* de Dirichlet a permis de stabiliser l’estimation des profils de motifs, tandis que la stratégie de redémarrages multiples et de *phase shifts* a prouvé son efficacité pour explorer un espace de solutions complexe marqué par de nombreux optima locaux. Les performances obtenues sur les données artificielles ($AJI \approx 0.80$) confirment la robustesse de l’algorithme lorsque le signal est clairement défini.

Limites et perspectives Cependant, l’expérimentation sur les séquences biologiques réelles du répresseur PurR ($AJI \approx 0.44$) souligne la distance entre les modèles mathématiques idéalisés et la complexité de la réalité biologique. Les résultats suggèrent que :

- Un modèle de fond d’ordre 0 est insuffisant pour capturer la structure complexe du génome d’*E. coli* (biais de composition, motifs répétés, etc.).
- La flexibilité biologique (mutations du site de fixation) nécessite des approches stochastiques encore plus souples.

Pour conclure, ce projet illustre parfaitement l’intérêt des méthodes de Monte Carlo par chaînes de Markov : elles permettent de transformer un problème d’optimisation globalement insoluble en une suite de tirages aléatoires locaux simples, offrant ainsi une solution élégante et performante aux défis de la science des données moderne.